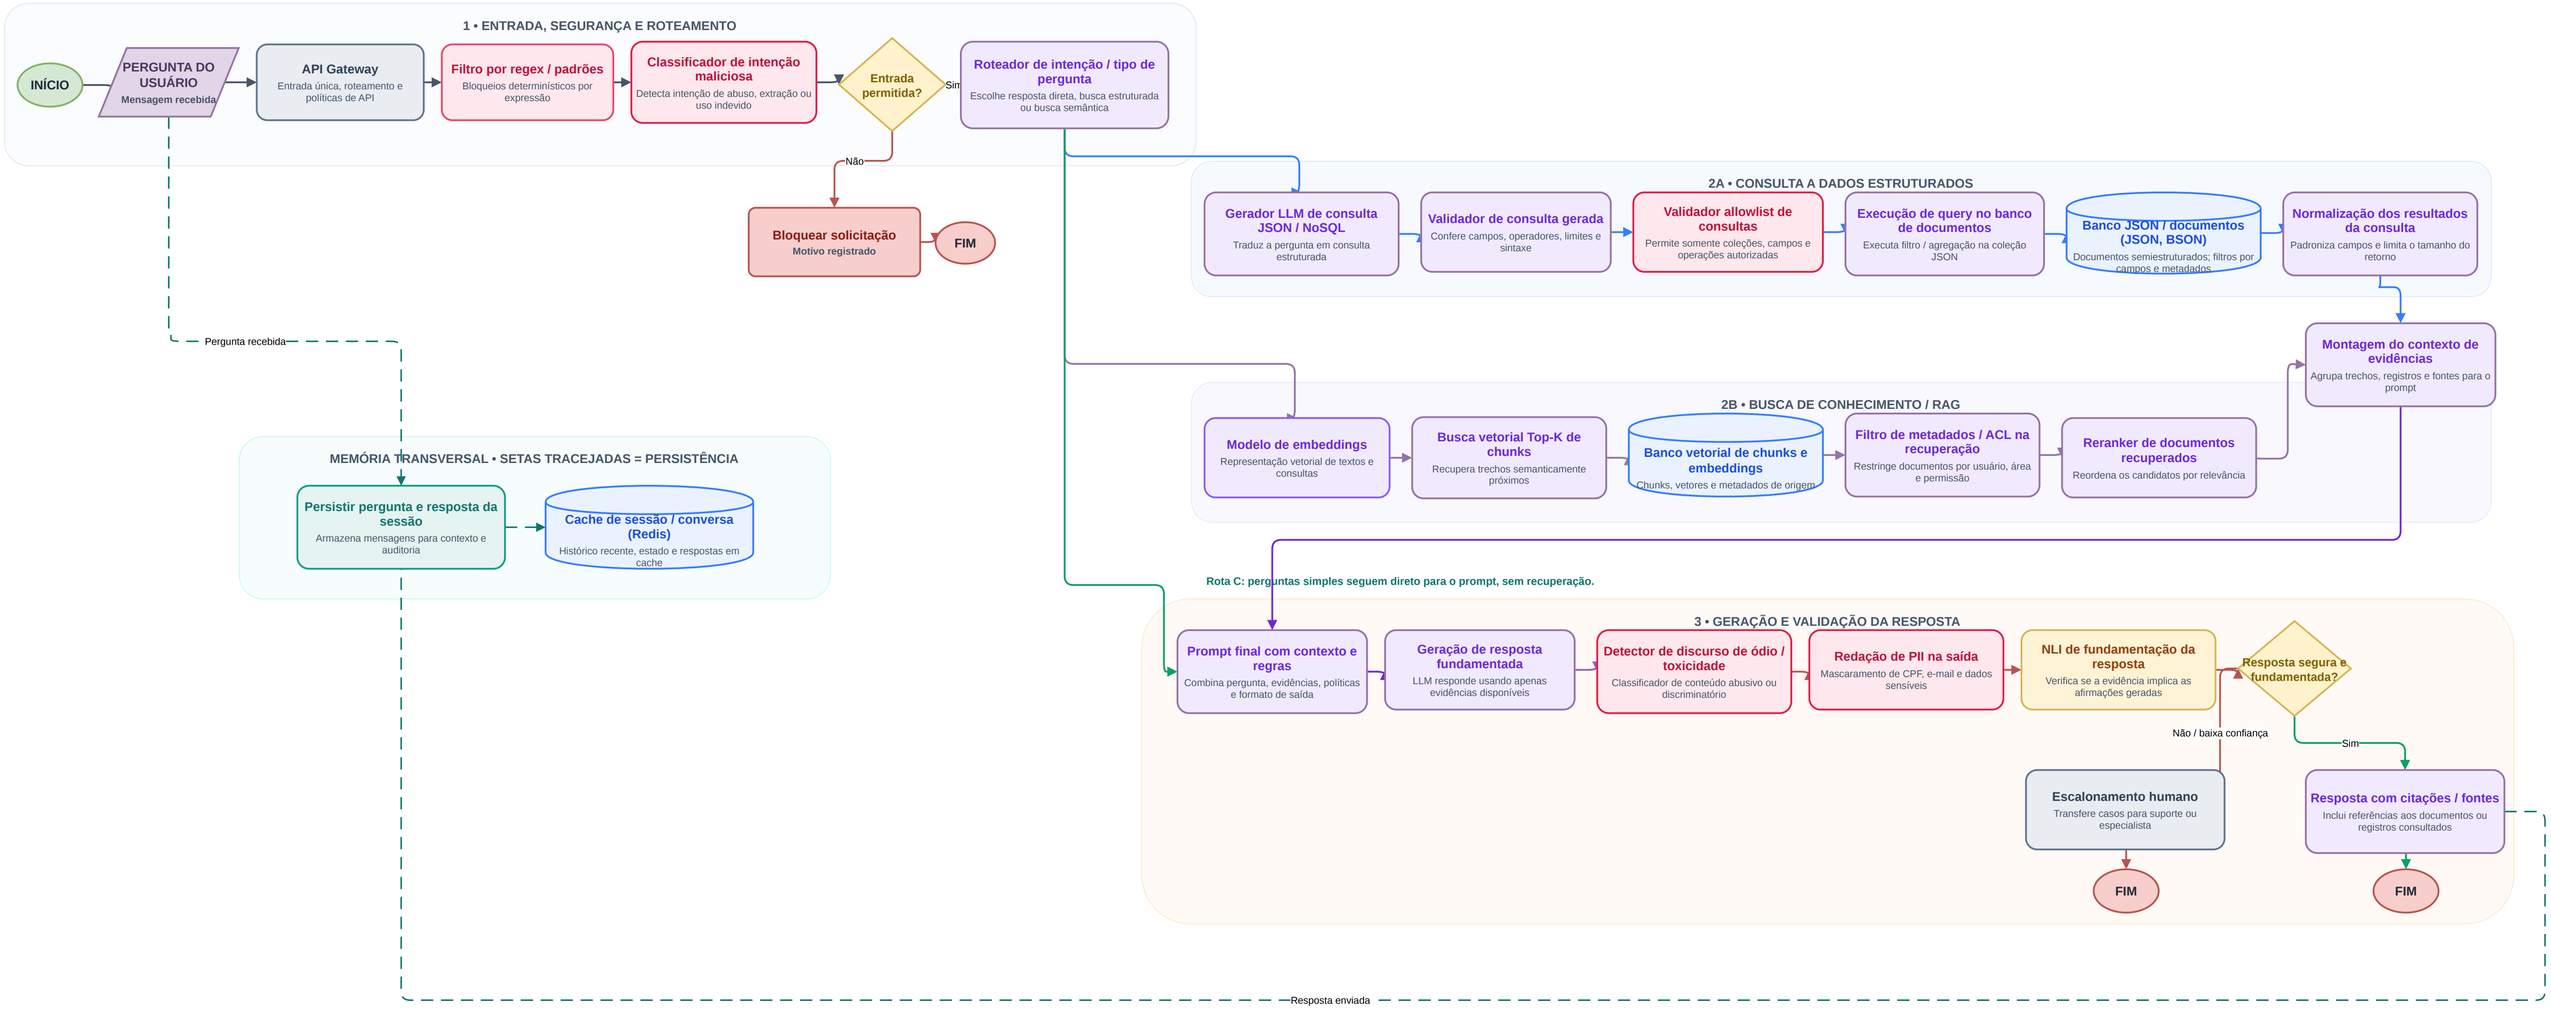
AGENTE DE CONSULTA A DADOS JSON E DOCUMENTAÇÃO

Exemplo didático: protege a entrada, escolhe a fonte de informação, gera uma resposta fundamentada e registra a conversa.

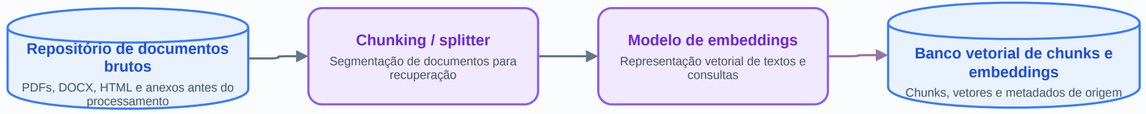


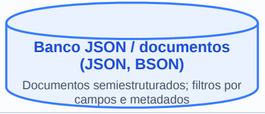
COMO A BASE É PREPARADA E COMO A ARQUITETURA PODE EVOLUIR

Estes componentes são extensões opcionais: acrescente-os quando houver um requisito que justifique custo e complexidade.

PREPARAÇÃO OFFLINE DA DOCUMENTAÇÃO

Documentos de origem → chunking → embeddings → banco vetorial





O banco JSON é consultado em tempo de execução. Já os documentos de referência são pré-processados e indexados antes da consulta.

SEGURANÇA ADICIONAL

Adicione controles de acordo com o modelo de ameaça, os dados e as permissões exigidas.

- **Detector de prompt injection** — Sinaliza instruções maliciosas e tentativas de fuga
- **Detector de vazamento de segredos** — Identifica tokens, chaves e credenciais
- **Validador de autorização por documento** — Confere se o usuário pode acessar cada fonte
- **Filtro de dados confidenciais** — Detecta informação interna restrita antes da resposta

RECUPERAÇÃO E QUALIDADE

Adicione quando busca, contexto ou qualidade de resposta precisarem ser revistos.

- **Busca híbrida** — Combina busca densa e lexical
- **Modelo de sumarização de documentos** — Gera resumos de documentos longos
- **LLM-as-a-judge para qualidade** — Avalia relevância, completude e aderência a critérios
- **Métricas de recuperação RAG** — Recall@K, relevância, diversidade e latência

RESILIÊNCIA E OPERAÇÃO

Adicione quando confiabilidade, custo, latência ou diagnóstico forem requisitos.

- **Circuit breaker / retry com limite** — Controla falhas repetidas e tentativas de recuperação
- **Fallback para modelo alternativo** — Direciona para um modelo ou estratégia de reserva
- **Timeout e cancelamento** — Interrompe chamadas lentas e libera recursos
- **Dashboard de latência e custo** — Tokens, tempo, custo e volume de chamadas

Atenção à memória: defina retenção, controle de acesso, minimização e remoção de dados sensíveis antes de gravar mensagens ou episódios.